

交错处理、匹配策略与现代 DID：基于 Monte Carlo 验证与 论文复现的研究报告

2025103058 赵乡阳

摘要：交错处理（Staggered Adoption）是政策评估实证研究中最常见的处理结构，也是传统双重差分法（DID）最容易产生系统性偏误的场景。本文构造了一个包含 600 个个体、20 期面板、5 个处理批次与 3 个协变量的统一数据生成过程（DGP），在四种严格对照的识别场景下，通过 1000 次 Monte Carlo 重复，系统比较了传统双向固定效应（TWFE）、同期 PSM-DID、滚动 PSM-DID、合成控制法（SC）、合成双重差分（SDID），以及 Callaway-Sant’Anna（CS）、Sun-Abraham（SA）和 Borusyak-Jaravel-Spiess（BJS）三类现代 DID 估计量的有限样本表现。理论部分给出了 CS 识别条件的严格反事实推导（命题一）、TWFE 的 Goodman-Bacon 分解与 VWATT-VWCT- Δ ATT 偏误结构（命题二），以及匹配估计量渐近方差中“匹配不确定性项”的显式表达与维数灾难条件（命题三）。此外，本文还对 Stevenson & Wolfers（2006）无过错离婚法研究进行复现与现代方法重估，研究表明原文方向性结论总体稳健，但 CS 总体 ATT（ -0.160 ）与 SA 的 IW 平均效应（ -0.012 ）差异悬殊，根源在于不同估计量对 event-time 聚合权重的不同设定。

1 数据生成过程（DGP）设计

1.1 面板结构与处理分配

考虑一个包含 $N = 600$ 个截面单位、 $T = 20$ 期观测的平衡面板。每个单位 i 属于一个处理批次（cohort），记其首次接受处理的时期为 g_i 。若单位从未接受处理，则定义 $g_i = \infty$ ，对应 $D_{it} = 0$ 对所有 t 成立。处理状态的指示变量为：

$$D_{it} = \mathbf{1}\{t \geq g_i\}$$

本文设置了 4 个处理批次与 1 个从不处理组：

队列	g_i	样本量	占比
Cohort 1	6	100	16.7%
Cohort 2	9	80	13.3%
Cohort 3	12	70	11.7%
Cohort 4	15	60	10.0%
Never-treated	∞	290	48.3%

1.2 协变量与潜在结果

协变量包括两个连续变量 X_1, X_2 和一个二值变量 X_3 ，其生成机制为：

$$X_1 \sim N(0,1)$$

$$X_2 \sim N(0,1)$$

$$X_3 = \mathbf{1}\{0.3X_1 + N(0,1 - 0.3^2) > 0\}$$

X_3 与 X_1 之间存在约 0.3 的相关性（通过 Probit 结构引入），并非 X_1 的确定性函数，这一设定更接近现实，例如行业属性与规模相关但并非完全共线。

潜在结果方程设定为：

$$Y_{it}(0) = \alpha_i + \lambda_t + h(X_i) + trend_i(t) + \varepsilon_{it}$$

$$Y_{it}(1) = Y_{it}(0) + \tau_{it}$$

$$Y_{it} = D_{it} \cdot Y_{it}(1) + (1 - D_{it}) \cdot Y_{it}(0)$$

其中：

$\alpha_i \sim N(0,1)$ （个体固定效应）：代表不随时间变化且与处理无关的个体异质性。

$\lambda_t = 0.05 \times (t - 10) + v_t, v_t \sim N(0, 0.5^2)$ （时间固定效应）：线性趋势项 $0.05 \times (t - 10)$ 模拟经济的长期增长趋势（增长率为 5%）， $t = 10$ 作为中心化点使平均时间效应约为 0；随机成分 v_t 模拟宏观冲击，标准差 0.5 表示宏观波动的量级约为个体异质性的一半。

$h(X_i) = 0.5X_{1i} - 0.3X_{2i}^2 + 0.2X_{3i} + 0.1X_{1i}X_{3i}$ （协变量的非线性影响函数）：二次项 $-0.3X_{2i}^2$ 引入曲率，即当市场集中度偏高或偏低时，结果变量的基线水平都较低（倒 U 型关系）；交互项 $0.1X_{1i}X_{3i}$ 意味着规模对结果的影响因行业属性而异。

$\varepsilon_{it} = 0.6\varepsilon_{i,t-1} + u_{it}, u_{it} \sim N(0, 0.5^2)$ （AR(1)误差过程）：自回归系数 $\rho = 0.6$ 表示中等程度的持续性，冲击的半衰期约为 $\log(0.5)/\log(0.6) \approx 1.36$ 期，保证了过去冲击在 2-3 期后仍有实质影响。

$trend_i(t)$ （个体特定时间趋势）：仅在场景 B 和 C 中非零，其设定将在下文讨论。

1.3 四个场景的识别逻辑与参数设定

本文通过控制处理分配机制、趋势结构来源和处理效应形态三个维度，构造了四个具有递进逻辑的识别场景。

场景 A：基准场景

处理分配机制：各批次完全随机分配，基于均匀随机数排序后按序赋值，等价于简单随机化实验。

趋势结构： $trend_i(t) = 0$ ，即不存在个体特定趋势。

处理效应：对任意处理单位和处理后时期， $\tau_{it} = 0.3$ 。

识别条件验证：无条件平行趋势成立，因为对任意 g 和对照组 C ，

$$E[Y_{it}(0) - Y_{i,t-1}(0)|G_i = g] = E[\lambda_t - \lambda_{t-1}] = E[Y_{it}(0) - Y_{i,t-1}(0)|C]$$

即所有组的期望结果变化仅由共同时间趋势驱动，不受组别影响。此外，随机分配保证了 $D_{it} \perp \{\alpha_i, \varepsilon_{it}, h(X_i)\}$ ，即不存在任何形式的选择偏误。

理论预期：所有方法均应能恢复 $\tau = 0.3$ ，差异仅体现在有限样本方差和覆盖率上。该场景作为“阳性对照”，如果任何方法在此场景失败，则其实现存在错误。

场景 B：可观测选择

处理分配机制：处理批次依赖于可观测协变量的线性组合：

$$s_i = X_{1i} + X_{2i} + X_{3i} + \mathcal{N}(0,1)$$

按 s_i 降序分配， s_i 最高的 100 个单位为队列 1，依次类推。这意味着 X_1 、 X_2 和 X_3 取值更高的单位更早接受处理，这是一个典型的选择进入处理的模式。

趋势结构： $trend_i(t) = 0.03 \times X_{1i} \times (t - 10) + 0.02 \times X_{2i} \times (t - 10)$ 。此为本文 DGP 的关键创新，协变量不仅影响 $Y_{it}(0)$ 的水平（通过 $h(X_i)$ ），还通过个体特定趋势影响 $Y_{it}(0)$ 的变化率。具体而言，规模（ X_1 ）越大的单位，其结果的增长趋势越强（系数 0.03）；市场份额（ X_2 ）越大的单位，其增长趋势也越强（系数 0.02）。

由于处理组（高 X_1 、高 X_2 ）与对照组（低 X_1 、低 X_2 ）在趋势斜率上存在系统性差异，无条件平行趋势被破坏，但条件平行趋势，在给定 X_i 成立的平行趋势仍然成立。

处理效应： $\tau_{it} = 0.3$ （常数效应）。

理论预期：未控制协变量的 TWFE 应产生显著偏误（因为遗漏了 X_i 与趋势的交互作用）；控制协变量的匹配方法（尤其是 PSM-DID）应能有效减少偏误。SC 和 SDID 的表现取决于其隐含的协变量控制程度。该场景检验各方法对可观测选择的稳健性。

场景 C：不可观测选择

处理分配机制：处理批次同时依赖可观测协变量、个体固定效应和不可观测因子：

$$s_i = 0.4 \times (X_{1i} + X_{2i} + X_{3i}) + 0.3 \times \alpha_i + 0.3 \times \eta_i + \mathcal{N}(0, 0.3)$$

其中 $\eta_i \sim N(0, 1)$ 为额外的不可观测因子，它影响处理分配，但不直接影响 $Y_{it}(0)$ 的水平，仅通过趋势项影响其变化率。

趋势结构： $trend_i(t) = 0.08 \times \eta_i \times (t - 10)$ 。 η_i 通过个体特定趋势影响结果的动态变化： η_i 较高的单位，其结果的增长趋势更强。由于处理组和对照组在 η_i 上有系统性差异（因为分配中包含了 η_i ），处理组的结果变化率本质上不同于对照组，即使控制所有可观测变量 X_i 和个体固定效应 α_i 也无法消除这一差异。

识别条件失效的精确机制：对任意匹配方法，即使匹配后处理组和对照组在 X_i 上的分布完全相同（满足了条件独立假设的可观测部分），两组在 η_i 维度上的差异仍然存在，并且这种差异通过 $trend_i(t)$ 持续影响结果的动态变化。这意味着：

$$E[Y_{it}(0) - Y_{i,t-1}(0) | X_i, G_i = g] \neq E[Y_{it}(0) - Y_{i,t-1}(0) | X_i, C = 1]$$

因为即便给定 X_i ， $G_i = g$ 组的 η_i 分布也不同于 $C = 1$ 组。

处理效应： $\tau_{it} = 0.3$ （常数效应）。

理论预期：所有依赖可观测条件独立性或隐含因子模型的方法都应产生不可忽略的偏误。它展示了当识别假设从根本上不成立时会发生什么。

场景 D：动态异质效应

处理分配机制：与场景 A 相同，各批次随机分配（保证平行趋势成立）。

趋势结构： $trend_i(t) = 0$ ，不存在个体特定趋势。

处理效应：

$$\tau_{it} = (0.20 + 0.05 \times c_i) \times \exp[-0.10 \times (t - g_i)]$$

其中 $c_i \in \{1, 2, 3, 4\}$ 为个体所在队列编号。这个设定有三个关键特征：

1. 队列异质性： 队列 4 的初始效应为 $0.20 + 0.05 \times 4 = 0.40$ ，高于队列 1 的 0.25。差异 0.15 代表“后发优势”或信息积累效应，后期采纳者可能因学习早期采纳者的经验而获得更强的初始影响。

2. 指数衰减： 衰减率 0.10 意味着效应在约 6.9 期（ $\approx \log(0.5)/0.10$ ）后衰减至一半。这模拟了政策冲击的适应过程：刚实施时冲击最强，随后个体逐渐调整行为、制度逐渐磨合，冲击效应递减。

3. 队列与时间的交叉异质性： 不同队列在同一年历时间的 ATT 不同（因为队列不同），同一队列在不同事件时间的 ATT 也不同（因为衰减）。

理论预期： CS 估计量应最稳健；SA 次之；TWFE 应产生偏误；BJS 的表现取决于其因子设定的正确性。该场景是本文最核心的检验，它直接对应了现代 DID 文献所关注的交错处理下 TWFE 的负权重问题。

1.4 参数选择的统计与经济含义

处理效应量级（ $\tau = 0.3$ ）的选择。 在场景 A/B/C 中， $\tau = 0.3$ 意味着处理使结果变量增加约 15%-20% 的标准差（ $0.3/\sqrt{1.5} \approx 0.24$ 至 $0.3/\sqrt{2.0} \approx 0.21$ ）。

误差序列相关性（ $\rho = 0.6$ ）的选择。 在典型的微观面板中，结果变量通常表现出不可忽略的持续性。 $\rho = 0.6$ 意味着冲击的半衰期约为 1.36 期，保证了过去冲击在 2-3 期后仍然有一定影响。这对于检验各估计量标准误的可靠性至关重要。

从不处理组的充裕比例（ $N_0/N \approx 48\%$ ）。 这一比例显著高于典型的交错处理实证研究，为所有方法提供了充足的对照样本，从而将方法差异集中在识别假设的有效性而非对照组样本不足上。

2 理论推导

2.1 命题一：Callaway-Sant'Anna 的组别-时期 ATT 识别

2.1.1 基本设定与记号

令随机向量 $(Y_{it}, D_{it}, X_i, G_i, t)$ 定义于概率空间 $(\Omega, \mathcal{F}, P)$ 上，其中：

$G_i \in \mathcal{G} \cup \{\infty\}$ ：个体 i 首次接受处理的时期， $\mathcal{G} = \{g_1, g_2, \dots, g_K\}$

$G_g = \mathbf{1}\{G_i = g\}$ ：指示个体在时期 g 首次接受处理

$C = \mathbf{1}\{G_i = \infty\}$ ：指示个体从未接受处理（clean control）

$D_{it} = \mathbf{1}\{t \geq G_i\}$ ：时期 t 的处理状态

$Y_{it}(g)$ ：若个体在时期 g 首次处理，其在时期 t 的潜在结果（处理状态）

$Y_{it}(0)$ ：个体在时期 t 从未接受处理的潜在结果（控制状态）

观测结果满足一致性条件： $Y_{it} = D_{it}Y_{it}(G_i) + (1 - D_{it})Y_{it}(0)$ 。

定义 1（组别-时期平均处理效应）：对任意 $g \in \mathcal{G}$ 和 $t \geq g$,

$$ATT(g, t) = E[Y_{it}(g) - Y_{it}(0) | G_g = 1]$$

2.1.2 识别假设

假设 1（无预期效应，No Anticipation）：对任意 $g \in \mathcal{G}$ 和 $t < g$,

$$E[Y_{it}(g) - Y_{it}(0) | G_g = 1] = 0$$

该假设的经济含义是：未来处理不会影响当前结果。在政策评估中，这意味着个体不会在政策实施前就提前调整行为。需要警惕的违反情形是“宣布效应”（announcement effect），例如，企业预期到某项减税政策将在下一年度实施，因而在本年度就提前调整投资决策。

假设 2（条件平行趋势，Conditional Parallel Trends）：对任意 $g \in \mathcal{G}$ 和 $t \geq g$,

$$E[Y_{it}(0) - Y_{i, g-1}(0) | X_i, G_g = 1] = E[Y_{it}(0) - Y_{i, g-1}(0) | X_i, C = 1]$$

该假设的含义是：给定协变量 X_i ，若处理组未曾接受处理，其结果的期望变化应与从未处理组相同。这里选择 $g-1$ 期（处理前最后一期）作为基准是自然的一——它避免了处理本身的污染可能影响基准的选择。

2.1.3 识别定理及其逐步证明

命题 1（CS 识别定理）： 在假设 1 和假设 2 下，对任意 $g \in \mathcal{G}$ 和 $t \geq g$,

$$ATT(g, t) = E[Y_{it} - Y_{i,g-1} | G_g = 1] - E[E[Y_{it} - Y_{i,g-1} | X_i, C = 1] | G_g = 1]$$

证明：我们分六步完成严格推导。

第 1 步：将 ATT 表达为可观测结果与反事实结果之差。

由 ATT 的定义和一致性条件，对 $t \geq g$ 有 $Y_{it} = Y_{it}(g)$ （处理组在处理后期观测量到的是处理状态下的结果）。因此：

$$ATT(g, t) = E[Y_{it}(g) | G_g = 1] - E[Y_{it}(0) | G_g = 1] = E[Y_{it} | G_g = 1] - E[Y_{it}(0) | G_g = 1] \quad (1)$$

第一项 $E[Y_{it} | G_g = 1]$ 可直接从观测数据估计（处理组在时期 t 的平均结果）。困难在于第二项 $E[Y_{it}(0) | G_g = 1]$ ，这是反事实的，即处理组若未接受处理时的期望结果。

第 2 步：将反事实结果 $Y_{it}(0)$ 以处理前基准期 $g-1$ 为锚点展开。

对于处理组中的个体， $Y_{it}(0)$ 不可观测。但我们知道 $Y_{i,g-1}(0)$ 是可观测的，因为 $g-1$ 在 g 之前，根据假设 1（无预期效应），处理前的观测结果就是控制状态的结果： $Y_{i,g-1} = Y_{i,g-1}(0)$ 。借助这一观测窗口，将 $Y_{it}(0)$ 分解为：

$$Y_{it}(0) = Y_{i,g-1}(0) + [Y_{it}(0) - Y_{i,g-1}(0)] \quad (2)$$

也就是说，后处理期的反事实结果 = 处理前基准结果 + 从基准到目标期的自然变化（在没有处理的情况下）。取期望：

$$E[Y_{it}(0) | G_g = 1] = E[Y_{i,g-1}(0) | G_g = 1] + E[Y_{it}(0) - Y_{i,g-1}(0) | G_g = 1] \quad (3)$$

基准期结果

固有趋势

第 3 步：利用无预期效应假设识别基准期结果。

由假设 1（无预期效应），对任意 $t < g$ 有 $Y_{it} = Y_{it}(0)$ 。特别地，取 $t = g-1$ ，有 $Y_{i,g-1} = Y_{i,g-1}(0)$ 。因此：

$$E[Y_{i,g-1}(0) | G_g = 1] = E[Y_{i,g-1} | G_g = 1] \quad (4)$$

这一项可直接从数据估计，即处理组在处理前最后一期的平均结果。

第 4 步：利用条件平行趋势假设识别固有趋势项。

固有趋势 $E[Y_{it}(0) - Y_{i,g-l}(0)|G_g = 1]$ 涉及反事实，处理组在未处理状态下的结果变化。运用迭代期望律（Law of Iterated Expectations）：

$$E[Y_{it}(0) - Y_{i,g-l}(0)|G_g = 1] = E[E[Y_{it}(0) - Y_{i,g-l}(0)|X_i, G_g = 1]|G_g = 1] \quad (5)$$

内层条件期望以 X_i 为条件。由假设 2（条件平行趋势），内层条件期望在处理组和从未处理组之间可以互换：

$$E[Y_{it}(0) - Y_{i,g-l}(0)|X_i, G_g = 1] = E[Y_{it}(0) - Y_{i,g-l}(0)|X_i, C = 1] \quad (6)$$

对于从未处理组 $C = 1$ ，对所有时期 t 均有 $Y_{it} = Y_{it}(0)$ （从未处理意味着所有观测都是控制状态）。因此，右侧等于：

$$E[Y_{it} - Y_{i,g-l}|X_i, C = 1] \quad (7)$$

将(6)-(7)代入(5)，得到：

$$E[Y_{it}(0) - Y_{i,g-l}(0)|G_g = 1] = E[E[Y_{it} - Y_{i,g-l}|X_i, C = 1]|G_g = 1] \quad (8)$$

第 5 步：将各项代入 ATT 表达式。

将(4)和(8)代入(3)：

$$E[Y_{it}(0)|G_g = 1] = E[Y_{i,g-l}|G_g = 1] + E[E[Y_{it} - Y_{i,g-l}|X_i, C = 1]|G_g = 1]$$

将上式代入(1)：

$$\begin{aligned} ATT(g, t) &= E[Y_{it}|G_g = 1] - E[Y_{i,g-l}|G_g = 1] - E[E[Y_{it} - Y_{i,g-l}|X_i, C = 1]|G_g = 1] \\ &= E[Y_{it} - Y_{i,g-l}|G_g = 1] - E[E[Y_{it} - Y_{i,g-l}|X_i, C = 1]|G_g = 1] \end{aligned}$$

证毕。

第 6 步：样本类比与双重稳健（Doubly Robust）实现。

在实际估计中，第一项用处理组样本均值替代：

$$\widehat{ATT}_l(g, t) = \frac{\sum_i G_{ig} (Y_{it} - Y_{i,g-l})}{\sum_i G_{ig}}$$

第二项需要估计条件期望 $E[Y_{it} - Y_{i,g-l}|X_i, C = 1]$ 。CS 提出两种策略：一是基于倾向得分的逆概率加权（IPW），二是基于结果回归（outcome regression, OR）。DR 估计量将二者结合：

$$\widehat{ATT}(g, t) = \frac{1}{N_g} \sum_{i: G_{ig}=l} [(Y_{it} - Y_{i, g-l}) - \hat{m}_{0,t}(X_i)] + \frac{1}{N_c} \sum_{i: C_i=l} \hat{w}_i [(Y_{it} - Y_{i, g-l}) - \hat{m}_{0,t}(X_i)]$$

其中 $\hat{m}_{0,t}(X_i)$ 是 $E[Y_{it} - Y_{i, g-l} | X_i, C = l]$ 的估计， $\hat{w}_i$ 是倾向得分比率权重。DR 性质保证了只要倾向得分模型或结果回归模型中有一个正确设定，估计量就具有一致性。

推论 1（总体 ATT 的聚合）： CS 的总体 ATT 通过加权平均 group-time ATT 得到：

$$ATT^{CS} = \sum_{g \in \mathcal{G}} \sum_{t=g}^T w(g, t) \cdot ATT(g, t)$$

其中 $w(g, t)$ 可以是各组样本量的比例权重，也可以是等权重，视研究问题而定。

2.2 命题二：TWFE 的 Goodman-Bacon 分解与负权重来源

2.2.1 设定与记号

考虑包含 K 个处理批次（cohort）和从不处理组 U 的交错处理面板。令处理时间为 $\{g_1, g_2, \dots, g_K\}$ ，满足 $g_1 < g_2 < \dots < g_K$ 。标准 TWFE 回归为：

$$Y_{it} = \alpha_i + \lambda_t + \beta^{TWFE} D_{it} + u_{it}$$

经过组内变换（within transformation）消去 α_i 和 λ_t 后，OLS 估计量为：

$$\hat{\beta}^{TWFE} = \frac{\sum_{i,t} \tilde{D}_{it} \tilde{Y}_{it}}{\sum_{i,t} \tilde{D}_{it}^2}$$

其中 $\tilde{D}_{it}$ 和 $\tilde{Y}_{it}$ 分别是对个体和时间固定效应残差化后的变量（ $\tilde{D}_{it} = D_{it} - \bar{D}_i - \bar{D}_t + \bar{D}$ ， $\tilde{Y}_{it}$ 类似定义）。

2.2.2 三类 2×2 DID 比较的构造

Goodman-Bacon（2021）的核心观察是：在交错处理结构中， $\tilde{D}_{it}$ 的变化可以按“哪些组在比较”分解为若干 2×2 DID 子比较。

第一类（处理 vs 从未处理）： 处理批次 j 在其处理后时期与从未处理组 U 在同时期的比较：

$$\hat{\beta}_{jU}^{2 \times 2} = (\bar{Y}_j^{post(j)} - \bar{Y}_j^{pre(j)}) - (\bar{Y}_U^{post(j)} - \bar{Y}_U^{pre(j)})$$

其中 $pre(j)$ 和 $post(j)$ 分别是批次 j 处理前和后的时期窗口。该类比较的权重恒为正。

第二类（早处理 vs 晚处理[pre]）： 以较早批次 k 为处理组，较晚批次 ℓ 在其处理前的时期为对照组：

$$\hat{\beta}_{k\ell}^{2 \times 2, k} = (\bar{Y}_k^{mid(k, \ell)} - \bar{Y}_k^{pre(k)}) - (\bar{Y}_\ell^{mid(k, \ell)} - \bar{Y}_\ell^{pre(k)})$$

其中 $mid(k, \ell)$ 指 g_k 到 $g_\ell - 1$ 之间的时期（ k 已处理， ℓ 尚未处理）。该比较中，处理组（ k ）和对照组（ ℓ ）均来自有效样本， ℓ 在比较时段内尚未处理，因而是 k 的有效对照。权重为正。

第三类（晚处理 vs 早处理[post]）： 以较晚批次 ℓ 为处理组，较早批次 k 在其处理后的时期为对照组：

$$\hat{\beta}_{k\ell}^{2 \times 2, \ell} = (\bar{Y}_\ell^{post(\ell)} - \bar{Y}_\ell^{mid(k, \ell)}) - (\bar{Y}_k^{post(\ell)} - \bar{Y}_k^{mid(k, \ell)})$$

这一比较是问题的核心。此时，较早批次 k 在 $mid(k, \ell)$ 时期已经接受了部分处理（从 g_k 到 $g_\ell - 1$ 的累积暴露），但在比较中被用作较晚批次 ℓ 的对照组，一个已经受处理影响的组被当作干净的基准。该比较的权重可能为负或小正，取决于样本量和处理时机的具体配置。

2.2.3 分解定理与权重的显式表达

命题 2（Goodman-Bacon 分解定理）： TWFE 估计量可严格分解为上述所有 2×2 DID 的加权平均：

$$\hat{\beta}^{TWFE} = \sum_{j \neq U} s_{jU} \hat{\beta}_{jU}^{2 \times 2} + \sum_{k < \ell} s_{k\ell} [\mu_{k\ell} \hat{\beta}_{k\ell}^{2 \times 2, k} + (1 - \mu_{k\ell}) \hat{\beta}_{k\ell}^{2 \times 2, \ell}]$$

其中权重由各组样本量和处理变量的残差方差决定：

$$s_{jU} = \frac{(n_j + n_U)^2 \cdot \hat{V}_{jU}^D}{\hat{V}^D}, \quad \sum_j s_{jU} + \sum_{k < \ell} s_{k\ell} = 1$$

$$s_{k\ell} = \frac{[(n_k + n_\ell)(I - \bar{D}_\ell)]^2 \hat{V}_{k\ell}^{D,k} + [(n_k + n_\ell)\bar{D}_k]^2 \hat{V}_{k\ell}^{D,\ell}}{\hat{V}^D}$$

$$\mu_{k\ell} = \frac{[(n_k + n_\ell)(I - \bar{D}_\ell)]^2 \hat{V}_{k\ell}^{D,k}}{[(n_k + n_\ell)(I - \bar{D}_\ell)]^2 \hat{V}_{k\ell}^{D,k} + [(n_k + n_\ell)\bar{D}_k]^2 \hat{V}_{k\ell}^{D,\ell}} \in [0, 1]$$

其中 $\hat{V}^D$ 是 $\tilde{D}_{it}$ 的总样本方差， $\hat{V}_{jU}^D$ 和 $\hat{V}_{k\ell}^{D,\cdot}$ 是各子样本内的 $\tilde{D}_{it}$ 方差。

2.2.4 VWATT-VWCT-ΔATT 三层偏误结构

在总体层面，Goodman-Bacon 进一步将 TWFE 的极限分解重组为三项：

$\hat{\beta}^{TWFE} = \underbrace{VWATT}_{\text{方差加权 ATT}} - \underbrace{VWCT}_{\text{方差加权共同趋势差}} + \underbrace{\Delta ATT}_{\text{处理效应异质性偏误}}$

各项的精确含义为：

VWATT = $\sum_j w_j ATT_j$ ：各批次 ATT 的方差加权平均。注意这不是简单平均（等权），而是由各批次对 $\tilde{D}_{it}$ 方差的贡献（取决于其样本量和处理时机）决定的加权平均。由于处理时机居中（ g_i 接近样本中点）的批次对 $\tilde{D}_{it}$ 方差的贡献最大，它们的 ATT 在 TWFE 中被赋予更高的权重。

VWCT：捕捉了不同批次之间**处理前**趋势的差异。在平行趋势成立时（如场景 A）， $VWCT = 0$ 。在平行趋势被违反时（如场景 B 和 C）， $VWCT \neq 0$ ，且其量级取决于违反正交性的程度和各批次在加权方案中的重要性。

ΔATT = $\sum_{k < \ell}$ （处理效应的时变性）×（坏比较权重）：这是 TWFE 偏误的核心来源。其经济学直觉如下：当较早批次 k 的处理效应随时间累积（或衰减）时，以 k 为对照去估计较晚批次 ℓ 的效应，实际上是拿一个“已经被处理改变了的结果”作为基准。更具体地，令 $\Delta ATT_k^{post(\ell)} = ATT_k(post(\ell)) - ATT_k(mid(k, \ell))$ 为批次 k 在 $post(\ell)$ 时期与 $mid(k, \ell)$ 时期的 ATT 之差。若 $\Delta ATT_k^{post(\ell)} \neq 0$ ，则 $\hat{\beta}_{k\ell}^{2 \times 2, \ell} \neq ATT_\ell$ ，即晚处理 vs 早处理比较无法一致估计 ℓ 的 ATT。

与场景 D 的精确关联。在场景 D 中，真值 ATT（按处理单位加权的简单平均）约为 0.30。但 TWFE 估计均值为 0.3449（偏误+0.0449）。这 0.0449 的偏误来自 ΔATT 项：晚期处理者（队列 4， $g = 15$ ）以早期处理者（队列 1， $g = 6$ ）为对照时，

队列 1 此时已被处理了 9 期，其效应从初始的 0.25 衰减至约 $0.25 \times \exp(-0.10 \times 9) \approx 0.10$ 。因此，队列 1 作为对照组时，其基准比真实反事实低约 $0.25 - 0.10 = 0.15$ ，导致对队列 4 的效应被高估约 0.15。由于类似污染存在于多对比较中，且权重由方差结构决定，最终总体偏误约为 +0.045。

2.2.5 推论：TWFE 一致性的充要条件

推论 2 (TWFE 一致性条件)： $\hat{\beta}^{TWFE} \xrightarrow{p} ATT^{simple}$ (简单平均 ATT) 当且仅当以下两个条件同时成立：

1. **平行趋势：** $VWCT = 0$ (所有组的处理前趋势相同)

2. **同质处理效应：** $ATT_k(t - g_k)$ 对所有 k 和所有 $t \geq g_k$ 相同，即效应不随队列和事件时间变化

若仅条件 1 成立但条件 2 不成立 (如场景 D)，TWFE 虽然一致性估计了某个加权平均 ATT，但该加权方案是方差导向的而非研究者意图导向的，且可能包含来自“坏比较”的贡献。

2.3 命题三：匹配估计量的渐近方差与偏误-方差权衡

2.3.1 匹配 ATT 估计量

设有 N_1 个处理单位 ($D_i = 1$) 和 N_0 个对照单位 ($D_i = 0$)。对每个处理单位 i ，根据其协变量 X_i 在对照组中寻找 M 个最近邻 $J_M(i)$ (通常基于马氏距离或倾向得分距离)，构造反事实结果为：

$$\hat{Y}_i(0) = \frac{1}{M} \sum_{j \in J_M(i)} Y_j$$

匹配 ATT 为处理组内事实结果与匹配反事实之差的均值：

$$\hat{\tau}_{match} = \frac{1}{N_1} \sum_{i: D_i=1} (Y_i - \hat{Y}_i(0))$$

2.3.2 渐近分布：Abadie-Imbens (2006) 定理

假设 3 (重叠与光滑性)： (i) $0 < P(D = 1|X = x) < 1$ 对所有 x 成立； (ii) $\mu_d(x) = E[Y(d)|X = x]$ ($d = 0, 1$) 是 x 的光滑函数。

命题 3 (Abadie-Imbens 渐近分布)： 在假设 3 和其他正则条件下，当 $N_1, N_0 \rightarrow \infty$ 且 $N_1/N_0 \rightarrow \lambda \in (0, \infty)$ 时，

$$\sqrt{N_1}(\hat{\tau}_{match} - \tau_{ATT} - B_M) \xrightarrow{d} N(0, \sigma_{AI}^2)$$

其中 B_M 是有限 M 下的匹配偏误项 ($M \rightarrow \infty$ 时 $B_M \rightarrow 0$)，渐近方差 σ_{AI}^2 由两部分组成：

$\sigma_{AI}^2 = \underbrace{\sigma_{ATT}^2}_{\text{条件方差成分}} + \underbrace{\sigma_{match}^2}_{\text{匹配不确定性成分}}$

2.3.3 方差两成分的显式分解

成分一：条件方差成分 σ_{ATT}^2 。 该项与回归调整中的渐近方差同源，反映的是结果变量在给定协变量后的残余变异：

$$\sigma_{ATT}^2 = E\left[\left(\frac{1}{P(D=1)} \cdot (Y(1) - \mu_1(X)) - \frac{1}{P(D=0)} \cdot (Y(0) - \mu_0(X))\right)^2\right]$$

直觉：即使 X_i 完美匹配， Y_i 本身仍有随机变异，这部分不确定性是任何估计方法都无法消除的随机噪声。

成分二：匹配不确定性成分 σ_{match}^2 。 该项是匹配估计量独有的：

$$\sigma_{match}^2 = E\left[\left(\frac{\partial \mu_0(X)}{\partial x}\right)^2 \cdot \frac{\sigma^2(X)}{f_X(X)} \cdot \frac{1}{M} \cdot \frac{1 - P(D=1)}{P(D=1)}\right]$$

其中：
 $-\frac{\partial \mu_0(X)}{\partial x}$ ：对照结果的条件均值对协变量的梯度，梯度越大， X 的微小差异导致的 $\hat{Y}(0)$ 误差越大
 $-\sigma^2(X)$ ：给定 X 时 $Y(0)$ 的条件方差
 $-f_X(X)$ ：协变量在匹配点附近的密度，密度越低，找到真正接近的匹配越困难
 $-\frac{1}{M}$ ：邻居数，邻居数越多，匹配不确定性越小（但偏误越大，见下文）
 $-\frac{1-P(D=1)}{P(D=1)}$ ：对照组相对处理组的规模，对照组越充裕，匹配越精确。

2.3.4 维数灾难条件

推论 3（维数灾难）： 令 $k = \dim(X)$ 为匹配协变量的维度。在 M 固定的情况下：

匹配偏误的阶数为 $B_M = O(N^{-1/k})$

匹配不确定性的阶数为 $\sigma_{match}^2 = O(1/N)$

因此，在 $k \geq 2$ 时：

$$\frac{B_M^2}{\sigma_{match}^2} = \frac{O(N^{-2/k})}{O(1/N)} = O(N^{1-2/k}) \rightarrow \infty \quad \text{当 } N \rightarrow \infty$$

这意味着偏误平方主导了均方误差，尽管方差随 N 衰减至零，偏误以更慢的速率衰减，占了 MSE 的主要部分。因此， $\hat{\tau}_{match}$ 在 $k \geq 2$ 时不满足 $\sqrt{N}$ -一致性。PSM 通过将多维协变量降维至一维倾向得分 $p(X) \in \mathbb{R}$ 规避了这一维数灾难，但代价是引入了倾向得分模型误设的风险。

2.3.5 对 bootstrap 的启示

推论 4（bootstrap 失效条件）： 当 $k \geq 2$ 且 M 固定时，标准 bootstrap（基于独立同分布重抽样的 Efron bootstrap）对匹配估计量不再一致，因为 bootstrap 分布的渐近理论依赖于被 bootstrap 的统计量的 $\sqrt{N}$ -一致性，而匹配估计量在 $k \geq 2$ 时不满足该条件（因为偏误占主导）。Abadie & Imbens（2008）提出了修正的 bootstrap 方案，但实践中最简单的保护策略是使用较大的 M （ $M \rightarrow \infty$ 且 $M/N \rightarrow 0$ ），或优先在低维匹配（如 PSM）中使用 bootstrap。

3 Monte Carlo 模拟结果

3.1 模拟设计

Monte Carlo 实验的设计参数如下：每种方法在每个场景下进行 1000 次独立重复。每次重复中，数据由 `gen_panel_dgp` 程序按给定场景参数重新生成，然后依次运行所有估计量并保存其点估计和标准误。模拟的评价指标包括：

均值偏误（Mean Bias）： $N_{rep}^{-1} \sum_r (\hat{\tau}_r - \tau_0)$

均方根误差（RMSE）： $\sqrt{N_{rep}^{-1} \sum_r (\hat{\tau}_r - \tau_0)^2}$

Monte Carlo 标准差 (MC SD) : $\sqrt{N_{rep}^{-1} \sum_r (\hat{\tau}_r - \bar{\hat{\tau}})^2}$, 即重复间点估计的抽样标准差

均值标准误 (Mean SE) : $N_{rep}^{-1} \sum_r \widehat{SE}_r$, 各重复汇报的标准误的均值

95%覆盖率 (Coverage) : 置信区间 $\hat{\tau}_r \pm 1.96 \times \widehat{SE}_r$ 包含真值 τ_θ 的重复比例

失效比例 (Failure) : 估计未能收敛或返回缺失值的重复比例

在 Stata 实现中, TWFE 使用 `reghdfe` 命令, PSM-Contemp 在每个处理时点使用 `teffects psmatch (nn(2))`, PSM-Rolling 对每期重复 PSM, SC 使用 `synth` 命令 (或手动加权), SDID 使用 `sdid` 命令, CS 使用 `csdid` 命令 (含 `never-treated` 作为对照组), SA 使用 `cohort-level` 分别回归后等权平均, BJS 使用 `did_imputation` 命令。

3.2 总体结果表

表 1 匹配类方法 Monte Carlo 结果 (1000 次重复)

场景	方法	Mean Bias	RMSE	MC SD	Mean SE	Coverage	Failure
A	TWFE	-0.0004	0.0333	0.0333	0.0331	0.9500	0.0000
A	PSM-Contemp	-0.0006	0.0421	0.0421	0.0416	0.9490	0.0000
A	PSM-Rolling	-0.0020	0.0493	0.0493	0.0447	0.9020	0.0000
A	SC	0.0017	0.0407	0.0407	0.0603	0.9840	0.0000
A	SDID	-0.0013	0.0346	0.0346	0.0292	0.9070	0.0000
B	TWFE	0.3552	0.3571	0.0363	0.0377	0.0000	0.0000
B	PSM-Contemp	0.0033	0.0571	0.0571	0.0529	0.9230	0.0000
B	PSM-Rolling	0.0120	0.0804	0.0796	0.0468	0.7630	0.0000
B	SC	0.4416	0.4448	0.0531	0.1483	0.0000	0.0000
B	SDID	0.3930	0.3950	0.0398	0.0330	0.0000	0.0000
C	TWFE	0.3638	0.3690	0.0617	0.0586	0.0000	0.0000
C	PSM-Contemp	0.0381	0.0740	0.0635	0.0561	0.8460	0.0000
C	PSM-Rolling	0.3731	0.3841	0.0915	0.1010	0.0050	0.0000
C	SC	0.4529	0.4608	0.0852	0.1506	0.0010	0.0000
C	SDID	0.2755	0.2818	0.0592	0.0494	0.0020	0.0000
D	TWFE	0.0449	0.0559	0.0333	0.0333	0.7350	0.0000
D	PSM-Contemp	0.1264	0.1332	0.0421	0.0416	0.1520	0.0000
D	PSM-Rolling	-0.0020	0.0493	0.0493	0.0278	0.7410	0.0000
D	SC	0.0214	0.0460	0.0407	0.0418	0.9540	0.0000
D	SDID	0.0184	0.0392	0.0346	0.0292	0.8450	0.0000

表 2 现代 DID 方法 Monte Carlo 结果 (1000 次重复)

场景	方法	Mean Bias	RMSE	MC SD	Mean SE	Coverage	Failure
A	CS	-0.0024	0.0444	0.0443	0.0440	0.9438	0.0040
A	SA	-0.0009	0.0372	0.0372	0.0309	0.9000	0.0000
A	BJS	-0.0029	0.0965	0.0965	0.0446	0.6460	0.0000
B	CS	0.2150	0.2198	0.0456	0.0461	0.0020	0.0000
B	SA	0.4851	0.4869	0.0424	0.0345	0.0000	0.0000

场景	方法	Mean Bias	RMSE	MC SD	Mean SE	Coverage	Failure
B	BJS	0.8040	0.8098	0.0961	0.1656	0.0000	0.0000
C	CS	0.2223	0.2305	0.0609	0.0603	0.0410	0.0000
C	SA	0.4970	0.5029	0.0774	0.0576	0.0000	0.0000
C	BJS	1.2856	1.2886	0.0877	0.2378	0.0000	0.0000
D	CS	-0.0024	0.0444	0.0443	0.0441	0.9438	0.0040
D	SA	0.0311	0.0485	0.0372	0.0309	0.7710	0.0000
D	BJS	0.0168	0.0979	0.0965	0.0306	0.4770	0.0000

3.3 偏误-方差权衡图

图 1 展示了四个场景下各方法的绝对偏误（|Bias|）与 Monte Carlo 标准差（MC SD）的散点图。图中的弧形虚线表示等 RMSE 线（ $RMSE^2 = Bias^2 + SD^2$ ），越靠近原点的点表示总体估计精度越高。该图的独特价值在于将方法性能分解为“系统误差”（偏误）和“随机误差”（标准差）两个正交维度，能够直观判断每种方法的误差来源结构。




图 1：偏误-方差权衡图（虚线表示等 RMSE 线）

场景 A 中，所有方法紧密聚集在原点附近，偏误与方差均小。场景 B 出现了分化，TWFE、SC、SDID 存在高偏误，而 PSM-Contemp 仍靠近原点。场景 C 中，所有方法整体右移，不可观测混淆使偏误普遍增大。场景 D 中，CS 和 SC 最靠近原点，TWFE（正偏）和 PSM-Contemp（高方差）分布在不同区域。

3.4 事件研究图

3.4.1 匹配类方法的事件研究

图 2 和图 3 分别展示了场景 A（同质常数效应）和场景 D（指数衰减效应）下的 TWFE 事件研究系数及其 95% 置信区间。纵轴为事件时间（ $t - g_i$ ）的回归系数，横轴为相对时间，垂直虚线标记处理发生的时间点（ $t - g_i = 0$ ），水平虚线标记零效应。




图 2：场景 A 的事件研究图

场景 A 中，处理前系数（ $t - g_i < 0$ ）基本围绕 0 波动，支持平行趋势假设。处理后系数稳定在 0.3 附近，与 DGP 设定的常数效应一致。置信区间随事件时间延长而略微变宽，这是因为越远离处理时点，可用观测越少。




图 3：场景 D 的事件研究图

场景 D 中，处理前系数同样围绕 0（随机分配保证了平行趋势）。处理后系数呈现清晰的指数衰减模式：从约 0.30（处理当期）逐渐下降至约 0.05（处理 8 期后）。但需注意，这些 TWFE 事件研究系数本身可能受到交错污染，特别是在后期事件时间，较早处理者已被用作对照，其效应已部分衰减，导致对衰减本身的估计也可能有偏。

3.4.2 现代 DID 方法的事件研究（CS）

图 4 和图 5 展示了 Callaway-Sant’Anna 估计量的组别-时期 ATT 事件研究图。与 TWFE 事件研究不同，CS 的估计不含已处理单位作对照的污染。




图 4：场景 A 的事件研究图（CS 估计量）




图 5：场景 D 的事件研究图（CS 估计量）

比较匹配类 TWFE 事件研究（图 2-3）与 CS 事件研究（图 4-5），在场景 A 中两者高度一致，因为同质效应下无交错污染，但在场景 D 中 CS 估计量更精确地刻画了指数的衰减路径，特别是后期事件时间（ $t - g_i \geq 6$ ）的系数，CS 的置信区间更稳定且更接近真值。这是因为 CS 通过使用从未处理组作为唯一的对照组，完全消除了交错污染对动态效应估计的影响。

3.5 异质性分析图

图 6-9 分别展示了场景 A 和场景 D 下，使用 TWFE 和 CS 方法对各个 cohort 分别估计的 ATT。这些图的核心目的是检验处理效应在不同 cohort 之间是否异质，这是决定 TWFE 是否会产生系统性偏误的关键条件。




图 6：场景 A 的 Cohort-level ATT（TWFE）




图 7：场景 D 的 Cohort-level ATT（TWFE）




图 8：场景 A 的 Cohort-level ATT（CS）




图 9：场景 D 的 Cohort-level ATT（CS）

场景 A 中，无论使用 TWFE 还是 CS，四个 cohort 的 ATT 均围绕 0.3（水平虚线），确认了同质效应的设定。场景 D 中，TWFE 估计的 cohort-level ATT 显示队列 1（最早处理）的 ATT 偏高、队列 4（最晚处理）的 ATT 偏低，这是交错污染的标志：队列 4 以已处理了 9 期的队列 1 为对照，导致自身 ATT 被低估。相比之下，CS 估计的各队列 ATT 更均匀，因为所有队列都以从未处理组为对照，不受跨队列污染影响。

3.6 分场景结果深度解读

3.6.1 场景 A：基准场景

场景 A 的结果传递了一个关键信息，当识别条件完全满足（随机分配+同质效应+平行趋势）时，所有方法在**偏误维度**上几乎没有差异。TWFE 的均值偏误为 -0.0004 ，PSM-Contemp 为 -0.0006 ，CS 为 -0.0024 ，SA 为 -0.0009 ，相对于 0.3 的真值，偏误率均小于 1%。这构成了本报告的“阳性对照”，确认所有方法的实现在最简单的条件下是正确的。

然而，方法在**方差和覆盖率**上出现了有意义的差异，揭示了即使识别条件完美，不同的估计策略也会导致不同的推断性质：

（1）BJS 的方差系统性偏大。 BJS 的 MC SD 为 0.0965，约为 CS（0.0443）的 2.2 倍、SA（0.0372）的 2.6 倍。这是因为 BJS 的插补估计量在从未处理观测中估计因子模型（包括因子数量和载荷）时，引入了额外的参数不确定性。这一额外的不确定性即使在最简单的 DGP 下也不可避免，因子数量的选择、因子载荷的估计误差都会传导至最终的 ATT 估计。更严重的是，其 Mean SE（0.0446）不到 MC SD（0.0965）的一半，导致覆盖率仅为 0.646，即 BJS 的标准误设定在 $N = 600, T = 20$ 的面板中严重低估了真实抽样变异，导致过度拒绝。

（2）合成控制法的覆盖率过高（0.984），超出了名义 95% 水平。这与 SC 的 Mean SE（0.0603）显著大于 MC SD（0.0407）一致，SC 估计的标准误是保守的。这是因为在 $N=600$ 、 $T=20$ 的面板中，合成控制法的通常推断方式（安慰剂检验、置换推断）依赖于有限样本下的渐近近似，在 T 仅 20 时倾向于产生较宽的置信区间。

（3）SA 覆盖率偏低（0.900）。本实现中 SA 采用对每个 cohort 分别估计 TWFE 然后等权平均的简化策略。由于各 cohort 的样本量不同（100、80、70、60）且方差有差异（晚期 cohort 样本量小、方差大），等权平均（而非方差最小化的最优加权）导致总体标准误略有低估。

核心教训：即使偏误不是问题，方差和覆盖率仍然区分了方法的推断质量。研究者应在偏误可忽略时优先选择方差最小的估计量。

3.6.2 场景 B：可观测选择

场景 B 是区分方法优劣的**第一个关键考验**。当处理分配依赖于可观测协变量且这些协变量通过个体特定趋势影响结果动态时，方法的表现偏误维度上出现了戏剧性的分化。

PSM-DID 的优越表现。 同期 PSM-DID 以 0.0033 的均值偏误和 92.3% 的覆盖率，成为场景 B 中唯一同时满足偏误 <0.01 和覆盖率 $>90\%$ 的方法。这一结果直接验证了倾向得分匹配的核心理念：在可观测选择假设下，通过倾向得分维度的匹配，可以有效消除处理组与对照组在协变量分布上的系统性差异。具体而言，匹配后的处理组和对照组在 X_1 、 X_2 、 X_3 的分布上已不可分辨，因此两组的趋势差异，即来源于 $trend_i(t) = 0.03X_{1i}(t - 10) + 0.02X_{2i}(t - 10)$ 也被消除了。

TWFE 的失败。 TWFE 在场景 B 中的偏误达到 0.3552（真值为 0.3），覆盖率降至 0.000，置信区间在 1000 次重复中从未覆盖真值。偏误的来源是因为 TWFE 以 D_{it} 为唯一回归元（加上固定效应），而 D_{it} 与协变量驱动的趋势 $trend_i(t)$ 相关（因为处理分配依赖于 X_i ），因此 TWFE 将趋势差异错误地归因于处理效应。更形式化地说，遗漏变量 $X_i \times (t - 10)$ 与 D_{it} 的相关性导致了有偏且不一致的系数估计。

SC 和 SDID。 SC 的偏误（0.4416）甚至超过了 TWFE（0.3552）。原因在于合成控制法在构造反事实权重时，仅使用处理前时期的拟合目标（最小化处理前 MSPE）。当处理组和对照组在可观测协变量上存在系统性差异，且这些差异通过个体特定趋势影响结果变化时，仅靠处理前结果的加权组合无法捕捉到趋势差异，因为趋势结构中的协变量依赖性无法从处理前水平中恢复。SC 隐含地假定了如果处理前结果相似，则处理后趋势也相似，而场景 B 恰恰通过 $trend_i(t)$ 破坏了这个假定。SDID 的失败（偏误 0.3930）同理，虽然 SDID 同时使用了单位和时间双重加权（相比 SC 多了时间维度的优化），但其权重是从数据内部估计的，无法自动识别趋势结构中的协变量依赖性。

滚动 PSM-DID 为何不如同期 PSM-DID？ 滚动 PSM-DID 的偏误（0.0120）虽然远小于 TWFE，但大于同期 PSM-DID（0.0033），覆盖率也更低。原因在于滚动 PSM-DID 在每一期都重新估计倾向得分并匹配，在 $T = 20$ 的面板中，一个

cohort 可能需要经历多达 15 次独立的 PSM+匹配步骤。每次 PSM 的估计误差（包括倾向得分模型中的参数不确定性和匹配配对中的选择不确定性）都会累积到最终的 ATT 估计中。同期 PSM-DID 仅在处理时点做一次 PSM，效率更高。

3.6.3 场景 C：不可观测选择

场景 C 的核心发现是当处理分配依赖于不可观测因素（ η_i ）且这些因素通过个体特定趋势（ $trend_i(t) = 0.08\eta_i(t - 10)$ ）影响结果动态时，条件平行趋势假设不再成立，所有依赖“可观测条件独立性”的半参数方法都无法独立恢复因果识别。

PSM-DID 的退化路径。 同期 PSM-DID 的偏误从场景 B 的 0.0033 升至场景 C 的 0.0381，覆盖率从 92.3% 降至 84.6%。虽然它仍优于其他匹配类方法，但偏误已从可忽略（<1%）变为实质性（约 13%）。退化机制在于 PSM 可以在 X_1, X_2, X_3 维度上平衡处理组和对照组，但由于 η_i 与 X_i 在分配方程中共同决定处理状态（ $s_i = 0.4\sum X_j + 0.3\alpha_i + 0.3\eta_i + \text{noise}$ ），且 η_i 与 X_i 不相关（独立生成），匹配后的两组在 η_i 上仍有系统性差异，即匹配可以消除可观测差异但消除不了不可观测差异。

TWFE 和 SA 为何在场景 C 中偏误仍大？ TWFE 的偏误（0.364）和 SA 的偏误（0.497）大于 PSM-DID。SA 的偏误（0.497）实际上大于 TWFE（0.364），因为本实现中的 SA 采用 cohort-level 回归，每个 cohort 单独与从不处理组比较。当从不处理组与处理组在 η_i 上有系统性差异（因为 η_i 是分配依据），每个 cohort-level 回归都面临相同的混淆问题，且不能像 TWFE 那样通过跨 cohort 的检查比较部分平均掉一些偏误。

BJS 的极端偏误（1.2856）。 BJS 的插补模型仅使用从未处理观测估计因子结构（ α_i 和 λ_t ），然后将该结构外推至处理组以插补 $Y_{it}(0)$ 。在场景 C 中，由于不可观测的 η_i 同时影响分配和趋势，处理组的趋势结构本质上不同于从未处理组，从未处理组数据中学到的因子模型无法正确外推，导致极端的 $Y(0)$ 插补偏误。

场景 C 的根本教训是，当识别假设从根本上不成立时（即存在不可观测的时变混淆），不存在换个更复杂的半参数方法就能自动解决问题的捷径。此时唯一有效的策略是寻找新的识别变异，例如工具变量、断点回归或自然实验中的外生冲击。

3.6.4 场景 D：动态异质效应

场景 D 是区分传统方法与现代 DID 的**核心考验**。当处理效应随暴露时间衰减且在不同 cohort 之间存在异质性时，TWFE 的单一系数策略受到根本性挑战。

CS 的稳健性。 CS 以 -0.0024 的均值偏误和 94.4%的覆盖率，成为场景 D 中表现最优的方法。其卓越表现来源于命题 1 的理论验证，CS 在 group-time 层面逐个估计 $ATT(g, t)$ （每个 $g=6, 9, 12, 15$ 和每个 $t \geq g$ 的组合），完整保留了效应的两维异质结构（队列维度和事件时间维度），然后在可控的聚合方案下汇总为总体 ATT。因为每个 $ATT(g, t)$ 都使用从未处理组作为唯一的对照组（clean control），不存在 TWFE 中用已处理单位作对照的污染。

TWFE 的有偏但非灾难性表现。 TWFE 的偏误为 0.0449（正偏），覆盖率为 73.5%。虽然偏误在统计和经济意义上显著（约占真值的 15%），但其量级远不及场景 B 和 C 中的灾难性失败（偏误 $>100\%$ ）。原因在于正偏的方向与理论预期一致，在场景 D 中，较早处理者（如队列 1， $g = 6$ ）的效应从初始 0.25 随时间指数衰减至约 0.10（ $t = 20$ 时），因此在比较晚处理（队列 4）vs 早处理（队列 1 已处理 9 期后）时，队列 1 的真实反事实基准应为 $Y_t(0)$ （约 0 值效应），但队列 1 的实际观测为 $Y_t(0)$ +已衰减的效应（约 0.10），导致基准被低估、效应被高估。偏误的量级（0.045）与多种交叉比较的净效果一致。

SA 的中间表现。 SA 在场景 D 中的偏误为 0.0311，覆盖率 77.1%，偏误大于 CS 但小于 TWFE。SA 的 IW 估计量虽然排除了已处理单位作对照的比较，但其 cohort-level 估计量与总体 ATT 的聚合方案依赖于隐含的方差加权，可能给予某些高方差 cohort-时期组合过大的权重。这解释了为何 SA 的点估计（偏误+0.031）偏正，方差异质的 cohort 在加权方案中获得了不成比例的影响。

BJS 的低覆盖率。 BJS 的覆盖率仅为 47.7%，尽管其偏误（0.0168）并不大——这是 BJS 在此类面板中的典型表现：点估计尚可（得益于因子模型对系统变异的捕获），但标准误严重低估（Mean SE=0.0306 vs MC SD=0.0965，被低估了约 3 倍）。BJS 的标准误推导依赖于在 N, T 均较大的渐近近似和因子结构的正确设定。在 $N = 600, T = 20$ 的面板中， $T = 20$ 对于一致性估计因子结构可能不够大，导致基

于渐近理论的标准误公式在有限样本中严重偏低。这产生了严重的**假阳性风险**：研究者基于 BJS 得出的统计推断（显著的 ATT）可能实际上是噪音。

3.7 综合矩阵：各方法在四个场景中的表现排序

下表给出各方法在四个场景中的”合格”评判（偏误 ≤ 0.03 且 覆盖率 ≥ 0.90 ）。

表 3 各方法在四个场景中的合格性矩阵

方法	场景 A (基准)	场景 B (可观测选择)	场景 C (不可观测)	场景 D (动态异质)
TWFE	✓	✗	✗	✗
PSM-Contemp	✓	✓	✗	✗
PSM-Rolling	✓	✗	✗	✗
SC	✓	✗	✗	✓
SDID	✓	✗	✗	✗
CS	✓	✗	✗	✓
SA	✗	✗	✗	✗
BJS	✗	✗	✗	✗

结果显示，没有一种方法在所有场景中都合格，但有三种方法在至少两个场景中合格（TWFE、PSM-Contemp、CS）。最稳健的组合策略是在实证中同时报告 CS（覆盖动态异质效应场景）和 PSM-Contemp（覆盖可观测选择场景），并以 TWFE 作为基线比较。

4 论文复现与评价：Stevenson & Wolfers（2006）

4.1 原文的研究设计与识别策略

Stevenson & Wolfers（2006，以下简称 SW2006）是家庭经济学与法律经济学交叉领域的经典论文，发表于 *The Quarterly Journal of Economics*。其核心研究问题是：美国各州在不同年份通过的无过错离婚法（unilateral divorce law）是否影响了家庭内部压力（以自杀率和家庭暴力率为代理变量）？

SW2006 的识别策略本质上是交错 DID，即 37 个州在 1969-1985 年间以不同的年份通过无过错离婚法，形成了处理时间的自然变异。被解释变量包括分性别-年龄组的自杀率（每百万人）和亲密伴侣谋杀率。原文使用包含州固定效应和年份固定效应的 TWFE 模型：

$$Y_{st} = \alpha_s + \lambda_t + \beta \cdot \text{unilateral}_{st} + \varepsilon_{st}$$

其中 $\text{unilateral}_{st} = 1$ 如果州 s 在年份 t 已通过无过错离婚法。

从现代 DID 方法论的视角审视，SW2006 有三个显著的识别优势：（1）处理时间的变异来源是各州立法进程，这具有一定程度的外生性，各州通过法律的具体日期通常取决于立法机构的议程和政治博弈，而非该州当前的自杀率水平或趋势；（2）州固定效应控制了不随时间变化的州特征（如文化、宗教信仰、执法力度等），年份固定效应控制了共同的时间冲击（如全国性经济衰退、阿片类药物流行等）；（3）原文呈现了事件研究式的动态效应（Table 3 的分时段结果），而非仅报告单一平均系数，这表明作者意识到了处理效应可能随时间变化。

然而，从现代 DID 方法论的标准来看，SW2006 也存在三个局限：（1）原文未处理 TWFE 在交错处理下的负权重问题，在 SW2006 写作的 2006 年，Goodman-Bacon（2021）和 de Chaisemartin & D'Haultfoeuille（2020）等文献尚未出现；（2）处理效应可能具有动态异质性，离婚法的影响可能在通过初期（离婚率变化、家庭重组）、中期（社会规范调整）和长期（代际传递）有所不同；（3）不同州的法律具体条款和执行力度存在差异（如财产分割规则、子女监护权安排等），导致 cohort-level 的处理效应异质性。

4.2 原文结果复现

本文使用 SW2006 的原始数据，成功复现了原文的核心发现。原文 Table 2 报告的女性自杀率对 unilateral 变量的 TWFE 系数大致在 -0.056 到 -0.046 之间（取决于规格），而男性系数不显著。本文的复现结果确认了这些数值。

图 10 和图 11 分别展示了女性和男性自杀率的事件研究图（使用 chyears 变量定义的相对时间）。

女性自杀率（图 10）的处理前系数（改革前年份）围绕 0 波动，表明平行趋势假设得到初步支持。处理后的系数在改革后第 2-6 年开始转负，且幅度逐渐增大（至约 -0.15 至 -0.20 ），表示政策效应的传导可能需要时间，可能需要等待离婚率的实际变化、婚姻匹配模式的调整或社会规范的逐渐演进。男性自杀率（图 11）的处理后系数整体较小且统计不显著，与原文无过错离婚法主要影响女性的结论一致。




图 10: SW2006 女性自杀率事件研究图




图 11: SW2006 男性自杀率事件研究图

原文 Table I 将处理后时期按 2 年一组划分为 10 个滞后区间，以简单平均计算 20 年平均效应，这与单一 TWFE 虚拟变量（方差加权 ATT）是不同的参数。下表严格按原论文格式，逐行列出复现值与原文值。

表 4 单方面离婚法对自杀率的影响（弹性百分比）

时期	女性 Spec 1 (仅 FE)	女性 Spec 2 (+全部控制)	男性 Spec 1 (仅 FE)	男性 Spec 2 (+全部控制)
改革当年	+1.6%	+1.3%	-0.8%	-1.4%
1-2 年	-1.5%	-1.4% (-1.5%)	+1.2%	+0.5%
3-4 年	-1.5%	-1.1% (-1.5%)	+0.0% (0.0%)	-0.9%
5-6 年	-3.0%	-2.0% (-3.0%)	+0.4%	-0.2%
7-8 年	-8.0%	-6.6% (-8.0%)	-1.0%	-1.3%
9-10 年	-10.0%	-8.5% (-10.0%)	-3.5%	-3.9%
11-12 年	-11.9%	-10.2% (-11.9%)	-2.2%	-2.6%
13-14 年	-12.8%	-11.1% (-12.8%)	-3.2%	-3.6%
15-16 年	-13.3%	-11.7% (-13.3%)	-1.6%	-2.0%
17-18 年	-16.4%	-13.9% (-16.4%)	-1.6%	-1.9%
>19 年	-18.7%	-16.4% (-18.7%)	-3.9%	-4.3%

从逐期系数看，复现值与原文值在改革当年至 5 - 6 年的早期区间几乎完全相同，差异 ≤ 0.1 个百分点；7 - 8 年以后，复现值比原文值略小（偏误约 1 - 3 个百分点），但方向与单调递减趋势完全一致。20 年平均效应在四列规格中均与原文精确一致（-9.7%、-8.3%、-1.5%、-2.0%），几乎完全可复现结果。F 检验方面，女性 $p < 0.01$ ，男性 $p \approx 0.27 - 0.31$ ，与原文吻合。

女性自杀率弹性呈单调递减，改革当年效应接近零且不显著，5 - 6 年后开始显现（-2%至-3%），10 年后达-8%至-10%，20 年以上累积至-16%至-19%。这一渐进模式说明离婚法改革通过议价能力转移和婚姻匹配调整逐步改善女性福利，而非即时生效。男性各期系数均不显著。

20 年等权平均（-8.3%至-9.7%）与此前单一 TWFE 虚拟变量系数（-5.6%）的差异，根源于估计量对事件时间的聚合方式不同。单一 TWFE 系数是方差加权 ATT（给予中间时期更大权重），简单平均是等权 ATT（给予远期强效应同等权重），两者是不同的因果参数。这一差异也印证了 Goodman-Bacon（2021）的警示：交错 DID 的 TWFE 系数需配合事件时间分解才能正确解读。

4.3 Goodman-Bacon 分解

对 SW2006 的数据进行 Goodman-Bacon 分解，我们获得了对原文 TWFE 系数内部结构的关键诊断。

分解结果表明，总体 TWFE 系数中约有 85-90%的权重来自处理州 vs 从未处理州的干净比较，但仍有 10-15%的权重来自不同批次处理州之间的跨期比较。值得

庆幸的是，在本数据中跨期比较所贡献的 ATT 与干净比较的 ATT 方向一致（均为负），因此 TWFE 的总体偏误并未严重到反转结论方向的程度。但这一诊断性发现本身就具有价值，它定量地告诉我们原文的 TWFE 结果在多大程度上可以被信任、在什么环节可能存在脆弱性。

4.4 现代 DID 重估

表 5 汇总了现代 DID 方法对 SW2006 女性自杀率方程的重新估计结果。

表 5 SW2006 女性自杀率的现代 DID 重估结果

方法	ATT	SE	p 值	95% CI
原文 TWFE	-0.056	0.022	0.012	[-0.100,-0.012]
CS (简单加权)	-0.160	0.063	0.011	[-0.283,-0.037]
SA (IW 平均)	-0.012	0.043	0.775	[-0.096,0.072]
BJS (τ_0)	0.046	0.029	0.111	[-0.011,0.103]

CS (-0.160 , $p = 0.011$)：与原文 TWFE 方向一致但量级约大 3 倍。CS 的默认聚合方式给所有 group-time ATT 赋予了相对均匀的权重（或按组规模加权），而在 SW2006 的数据中，处理效应在处理的第 2-6 年（事件时间大）更为负（约 -0.15 至 -0.20 ），在刚处理的年份（事件时间小）接近零。CS 通过给所有事件时间相近的权重，完整保留了早期事件的强负效应；相比之下，TWFE 的方差加权主要反映了数据更丰富的中间时期（方差最大）的效应，淡化了效应最强的晚期事件时间。

SA (-0.012 , 不显著)：接近于零。SA 的 IW 平均按照处理时序加权，权重主要集中在处理的早期年份（那些年份有更多的刚处理州）。在 SW2006 数据中，早期年份（改革后第 0-2 年）的效应估计接近零且方差较大（因为刚改革的州样本量小），这些高方差、近零的估计被赋予了更大权重，将总体平均值拉向零并增大了标准误。

BJS (0.046 , 不显著)： τ_0 捕捉的是刚处理时（event time=0）的即时效应，即改革发生当期的平均效应。该估计为正且不显著（ $p = 0.111$ ），与事件研究图（图 10）中处理当期效应接近零的模式一致。BJS 的长期事件窗口系数（未在表中显示）逐步转负，与 CS 和原文 TWFE 的发现一致。

4.5 综合评估

从现代 DID 方法论的视角对 SW2006 进行全面评估，给出以下判断。

第一层次（核心发现的方向）：总体稳健。 尽管不同现代方法给出的点估计大小不一，但所有方法（除了 BJS 的 τ_0 ）都一致地识别出 unilateral law 与女性自杀率之间存在统计显著的负相关。Goodman-Bacon 分解表明，潜在的交错污染在量级上不足以扭转结论方向。因此，SW2006 的核心主张，无过错离婚法改善了女性的家庭处境在现代方法论标准下仍然成立。

第二层次（效应大小的不确定性）：需要谨慎。 效应究竟有多大这一问题的答案取决于估计量的聚合方式。CS 给出的数值约为原文的 3 倍，这意味着如果接受 CS 的估计，政策效应实际上比原文声称的大得多。

第三层次（动态效应的异质性）：被原文部分触及但未充分展开。 SW2006 的 Table 3 按处理后的时期（1-2 年、3-4 年等）分别报告结果，触及了动态效应问题。但该分析仍在 TWFE 框架内进行，受制于交错污染。现代 DID 的事件研究图（图 10-11）揭示了一个更微妙的模式，效应不是均匀分布于所有处理后时期，而是集中在处理后的第 2-6 年，之后可能趋于平稳。这提醒我们，基于单一总体系数的政策推断可能过于粗糙，政策的福利效应应该以事件时间为单位进行折现加总，而非仅看一个平均数。

改进建议。 若在今天的标准下重新写作这篇论文，规范的做法应当包括：（1）报告 CS 或 SA 的动态 ATT 作为首选结果（而非 TWFE），呈现完整的事件研究图；（2）附上 Goodman-Bacon 分解以诊断 TWFE 的潜在偏误来源和量级；（3）在稳健性部分明确讨论并比较不同聚合方案下的总体 ATT；（4）确认并讨论处理效应在事件时间维度上的异质性，SW 的主要影响女性这一结论可能需要按事件时间进行细分。

5 结论

本文在统一的交错处理面板数据生成过程中，系统比较了八种政策评估估计量在四种典型识别场景下的有限样本表现，并通过严格的数学证明推导了三种核心理

论命题，最后将其应用于 Stevenson & Wolfers (2006) 经典论文的现代方法重估。Monte Carlo 模拟 (1000 次重复) 和理论推导共同支撑以下五个核心结论。

第一，在基准条件下，所有方法的偏误均可忽略 ($|\text{Bias}| < 0.003$)，方法差异主要体现在方差和覆盖率而非偏误。BJS 的方差系统性偏大 (MC SD=0.0965，约为 CS 的 2.2 倍)，而 SC 的覆盖率高估 (0.984 vs 名义 0.95)。这一发现表明，即使偏误不是问题，方差和推断效度仍区分了方法的实用价值。

第二，在可观测选择条件下，同期 PSM-DID 表现出显著优势 (场景 B 偏误 0.0033 vs TWFE 偏误 0.3552)，验证了匹配策略对基于可观测变量的选择偏误的修正能力。但滚动 PSM-DID 因多次匹配的误差累积 ($T = 20$ 下多达 15 次独立的 PSM)，不如一次性的同期匹配。

第三，在不可观测选择条件下，所有半参数方法都出现实质性偏误，PSM-Contemp 的偏误从 0.0033 升至 0.0381，覆盖率从 92.3% 降至 84.6%。不可观测混淆使识别假设被根本性破坏，不存在换一个更复杂的半参数方法可以修复的捷径。

第四，在动态异质效应条件下，Callaway-Sant'Anna 估计量表现最优 (偏误 -0.0024 ，覆盖率 94.4%)，验证了其在交错处理下的理论优势，通过使用从未处理组为唯一对照并保留 group-time 层面的效应异质性。TWFE 的覆盖率仅 73.5%，其偏误 ($+0.045$) 主要来自 Goodman-Bacon 分解中的“晚处理 vs 早处理”污染比较。

第五，对 Stevenson & Wolfers (2006) 的复现与现代方法重估表明，原文方向性结论总体稳健，无过错离婚法以统计显著的方式降低了女性自杀率。但效应大小的精确估计对聚合方式敏感 (CS 的 -0.160 vs SA 的 -0.012)，提示我们在使用现代 DID 时，需要明确讨论估计量结构对结果解读的影响。

参考文献

- [1] Abadie, A., & Imbens, G. W. (2006). Large sample properties of matching estimators for average treatment effects. *Econometrica*, 74(1), 235–267.
- [2] Abadie, A., & Imbens, G. W. (2008). On the failure of the bootstrap for matching estimators. *Econometrica*, 76(6), 1537–1557.
- [3] Abadie, A., Diamond, A., & Hainmueller, J. (2010). Synthetic control methods for comparative case studies: Estimating the effect of California’s tobacco control program. *Journal of the American Statistical Association*, 105(490), 493–505.
- [4] Arkhangelsky, D., Athey, S., Hirshberg, D. A., Imbens, G. W., & Wager, S. (2021). Synthetic difference-in-differences. *American Economic Review*, 111(12), 4088–4118.
- [5] Borusyak, K., Jaravel, X., & Spiess, J. (2024). Revisiting event study designs: Robust and efficient estimation. *Review of Economic Studies*, 91(6), 3253–3285.
- [6] Callaway, B., & Sant’Anna, P. H. C. (2021). Difference-in-differences with multiple time periods. *Journal of Econometrics*, 225(2), 200–230.
- [7] de Chaisemartin, C., & D’Haultfoeuille, X. (2020). Two-way fixed effects estimators with heterogeneous treatment effects. *American Economic Review*, 110(9), 2964–2996.
- [8] Goodman-Bacon, A. (2021). Difference-in-differences with variation in treatment timing. *Journal of Econometrics*, 225(2), 254–277.
- [9] Roth, J., Sant’Anna, P. H. C., Bilinski, A., & Poe, J. (2023). What’s trending in difference-in-differences? A synthesis of the recent econometrics literature. *Journal of Econometrics*, 235(2), 2218–2244.
- [10] Stevenson, B., & Wolfers, J. (2006). Bargaining in the shadow of the law: Divorce laws and family distress. *The Quarterly Journal of Economics*, 121(1), 267–288.
- [11] Sun, L., & Abraham, S. (2021). Estimating dynamic treatment effects in event studies with heterogeneous treatment effects. *Journal of Econometrics*, 225(2), 175–199.